AXMOS

UNLOCK THE EXTRAORDINARY

Gemini + TimesFM en BigQuery: ¿quién vio venir la tormenta?

Workshop hands-on con datos reales del octubre más lluvioso de Santiago

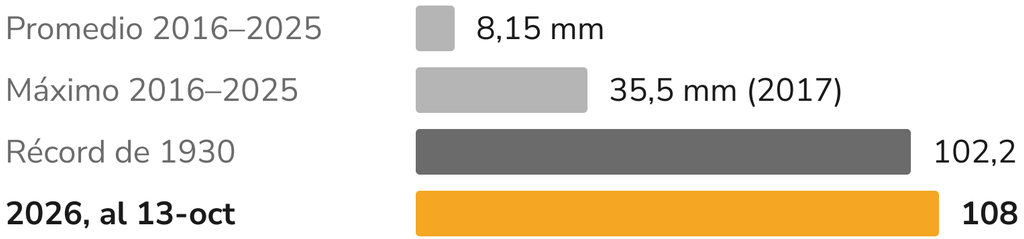
DEVFEST CLOUD SANTIAGO 2026 · 17 OCT · JAVIER ARCE NAVEA



Octubre 2026 en Santiago, comparado con lo normal

LLUVIA DE OCTUBRE · QUINTA NORMAL

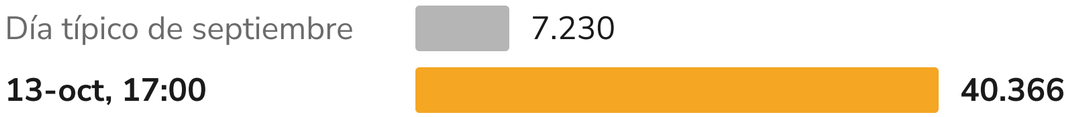
~13× un octubre normal



DMC, estación 330020 · récord: CR2, preliminar

CLIENTES SIN LUZ · REGIÓN METROPOLITANA

~5,6× un día normal



Día típico = mediana del peak diario de septiembre · SEC

Y en la misma semana: el aluvión de Quebrada Honda del jueves 8, a pocos kilómetros de esta sala (384 damnificados, Senapred), y un tornado EF0 en Estación Central el martes 13.

La pregunta del día

¿Quién vio venir la tormenta?

Cuatro testigos. A cada uno le preguntamos cómo funciona, qué vio y dónde se equivoca.

01 · LA PRENSA
Lo que contamos

02 · EL SATÉLITE
Lo que se veía

03 · LA SERIE
Lo que sintió la red eléctrica

04 · UN AGENTE
Lo que sabemos preguntar

Ninguno basta solo: *el valor está en cruzarlos, y en saber cuándo no creerles.*

Presentación y contenidos



Javier Arce Navea
Cloud Data & AI Engineer
Axmos Technologies
linkedin.com/in/jarcen

GOOGLE CLOUD AMBASSADOR LATAM · CERTIFIED ×11









01	**La prensa** Qué es un LLM dentro del SELECT	10 min
02	**El satélite** Cómo ve un modelo una imagen	12 min
03	**La serie** Qué es un modelo fundacional de series	13 min
04	**Un agente** Qué es un data agent y una capa semántica	9 min

Todo en SQL. Sin connection, sin CREATE MODEL, sin Python.

Paso 0: tus créditos de Google Cloud

1. Escanea el QR e inicia sesión con **tu cuenta de Google**.
2. Si te lo pide, crea tu perfil de **Google Developer Program**.
3. **Claim credit** y después **Open Billing Account**. La cuenta **GDP Credit** puede tardar hasta 5 minutos en aparecer.
4. En **console.cloud.google.com** crea un **proyecto nuevo** y vincúlale esa cuenta de facturación.



g.dev/credits/gdg-cloud-santiago-de-chile-2

Incluye BigQuery, Cloud Storage y las APIs de Agent Platform (Gemini).

No incluye AI Studio: todo el lab se hace en BigQuery.

Prepara tu entorno: 2 comandos, ~2 minutos

1. En **console.cloud.google.com**, elige **el proyecto con tus créditos** y abre **Cloud Shell** (el ícono de terminal, arriba a la derecha).

2. Copia y ejecuta los dos comandos de la derecha.

3. Mientras se ejecuta, te muestro qué datos vas a tener.

```
# en Cloud Shell, con tu proyecto seleccionado
gcloud storage cp \
  gs://devfest-demo-bq-lab/setup/setup_asistente.sh .
bash setup_asistente.sh
```

QUÉ HACE EN TU PROYECTO (US-EAST1)

- Bucket **<tu-proyecto>-devfest** con las imágenes satelitales (~35 MB)
- Dataset **fuentes**: copia de 7 tablas · dataset **trabajo**: vacío
- Habilita las APIs de BigQuery, Vertex AI y Conversational Analytics

AL FINAL DEBES VER

`noticias 120 · peak_sec 40366 · horas_satelite 1034 · dias_lluvia 72589 · tablas_trabajo 0`

Los datos: lo que te entregamos y lo que tú creas

fuentes.	Qué es	De dónde	Filas
noticias	titulares y resúmenes, 5 al 14-oct	prensa chilena	120
lluvia_dmc_diaria	mm por estación y día, desde 2016	DMC	72.589
estaciones_dmc	estaciones con ubicación	DMC	146
sec_rm_horario	clientes sin luz en la RM, por hora	SEC	1.047
sec_rm_comuna_horario	lo mismo, por comuna	SEC	54.444
sec_clientes_sin_luz	todas las regiones, por comuna y hora	SEC	178.712
satelite_horario	lo que Gemini vio en cada imagen infrarroja, hora a hora	GOES-19 vía NASA GIBS + Gemini	1.034

fuentes

Lo que te entregamos. Solo se lee.

trabajo

Lo que tú creas. Empieza vacío y se llena con cada paso del lab.

Y en tu bucket, 1.034 imágenes infrarrojas (una por hora) y 84 recortes en color.

Todas las queries dicen fuentes.X o trabajo.X: *sin nombre de proyecto, funcionan en el tuyo.*

Ejecútalo ahora: te explico mientras carga

1. Abre **BigQuery Studio** en **tu proyecto** (el mismo del paso anterior)
2. Tus datos están en el dataset **fuentes** (us-east1); lo que crees va a **trabajo**
3. Ejecuta la primera query: si ves 3 filas con su impacto, estás listo

```
-- 01 · prueba de humo
SELECT titular,
  AI.CLASSIFY(titular,
    categories ⇒ ['vivienda', 'energia',
      'transporte', 'educacion',
      'agua']) AS impacto
FROM fuentes.noticias
ORDER BY url
LIMIT 3;
```

Puede tardar hasta ~40 s si todos ejecutan a la vez: es normal. Sin connection: se ejecuta con tus credenciales.

Dos modelos fundacionales, una misma idea

GEMINI

Preentrenado con **texto e imágenes**.

Le das un **prompt** y completa **texto**.

TIMESFM

Preentrenado con **series de tiempo**.

Le das una **historia** y completa la **curva**.

Se entrenan **una vez**, con muchísimos datos de todo tipo

Se usan **sin entrenar** (zero-shot): el contexto lo pones tú

Devuelven una **predicción**, no una verdad

No entrenas el modelo: *le das contexto.*

AXMOS
UNLOCK THE EXTRAORDINARY

01

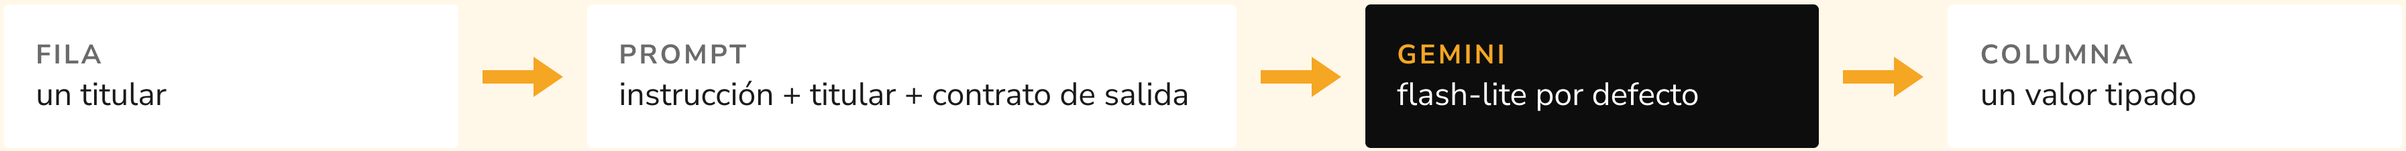
TESTIGO 01 DE 04

La prensa

La vio después. ¿Se pusieron de acuerdo?

AI functions en el SELECT, el WHERE y el GROUP BY sobre 120 titulares reales.

Qué pasa cuando escribes AI.CLASSIFY



Una llamada al modelo por fila: 120 titulares son 120 llamadas.

Se paga en tokens, no en bytes: los 120 titulares suman 5.562 tokens.

Es probabilístico: la misma pregunta puede dar otra respuesta.

Cada función es un contrato: AI.IF → BOOL · AI.CLASSIFY → una etiqueta de tu lista · AI.SCORE → un número.

Sin connection: se ejecuta con tus credenciales.

Sin endpoint usa el modelo por defecto, el más rápido. Cambiarlo es un argumento.

> ***Cada fila es un prompt.*** *Cada columna es un contrato.*

Tres funciones, una sola query

GA · abr 2026

```
SELECT titular,
  AI.CLASSIFY(titular, categories ⇒ [
    'vivienda', 'energia', 'agua', 'transporte',
    'educacion', 'salud', 'otro']) AS impacto,
  AI.SCORE(('Gravedad humana de 1 a 10: ', titular)) AS gravedad
FROM fuentes.noticias
WHERE AI.IF(('¿Critica la respuesta de las autoridades? ', titular))
ORDER BY gravedad DESC;
```



QUÉ HACE AI.IF EN EL WHERE

Es un filtro: le hace la pregunta al modelo **fila por fila**. Si responde TRUE, la fila pasa; si responde FALSE, queda fuera. Recién sobre las filas que pasan se ejecutan AI.CLASSIFY y AI.SCORE.

AI.IF · EL FILTRO

~15 de 120 notas critican a las autoridades.[1] Revisa si hay falsos positivos.

AI.CLASSIFY · UNA ETIQUETA

Aluvión → **vivienda**. Cortes → **energía**. Clases → **educación**.

AI.SCORE · UN NÚMERO

Gravedad de 1 a 10 por titular. Entre una ejecución y otra puede moverse **±2**.

La query completa: **9 a 12 s**.

[1] El resultado puede variar entre ejecuciones (modelo probabilístico).

AI.AGG: ¿por qué cada medio da otra cifra?

GA · 13 oct 2026

```sql
SELECT evento,
  COUNT(*) AS notas,
  AI.AGG(
    CONCAT(medio, ': ', titular, '. ', bajada_o_extracto),
    '''Explica en máximo 4 viñetas, en español, por qué
    los medios dan cifras distintas de clientes sin luz.
    Cita el medio de cada cifra.'''
  ) AS explicacion
FROM fuentes.noticias
WHERE REGEXP_CONTAINS(
  LOWER(CONCAT(titular, ' ', bajada_o_extracto)),
  r'luz|eléctric|clientes')
GROUP BY evento
ORDER BY notas DESC;
```

LO QUE ENCONTRÓ · ~6 S · 3 GRUPOS

36.924 · 35 mil · 40 mil · 41 mil · 43.025

Hora de corte: cada medio miró la SEC a otra hora

Fuente: SEC frente a Enel

Redondeo: "más de 40 mil"

Unidad: clientes no es lo mismo que hogares

Un **GROUP BY que razona**: lee todas las filas del grupo y devuelve un solo texto por grupo.

AXMOS
UNLOCK THE EXTRAORDINARY

02

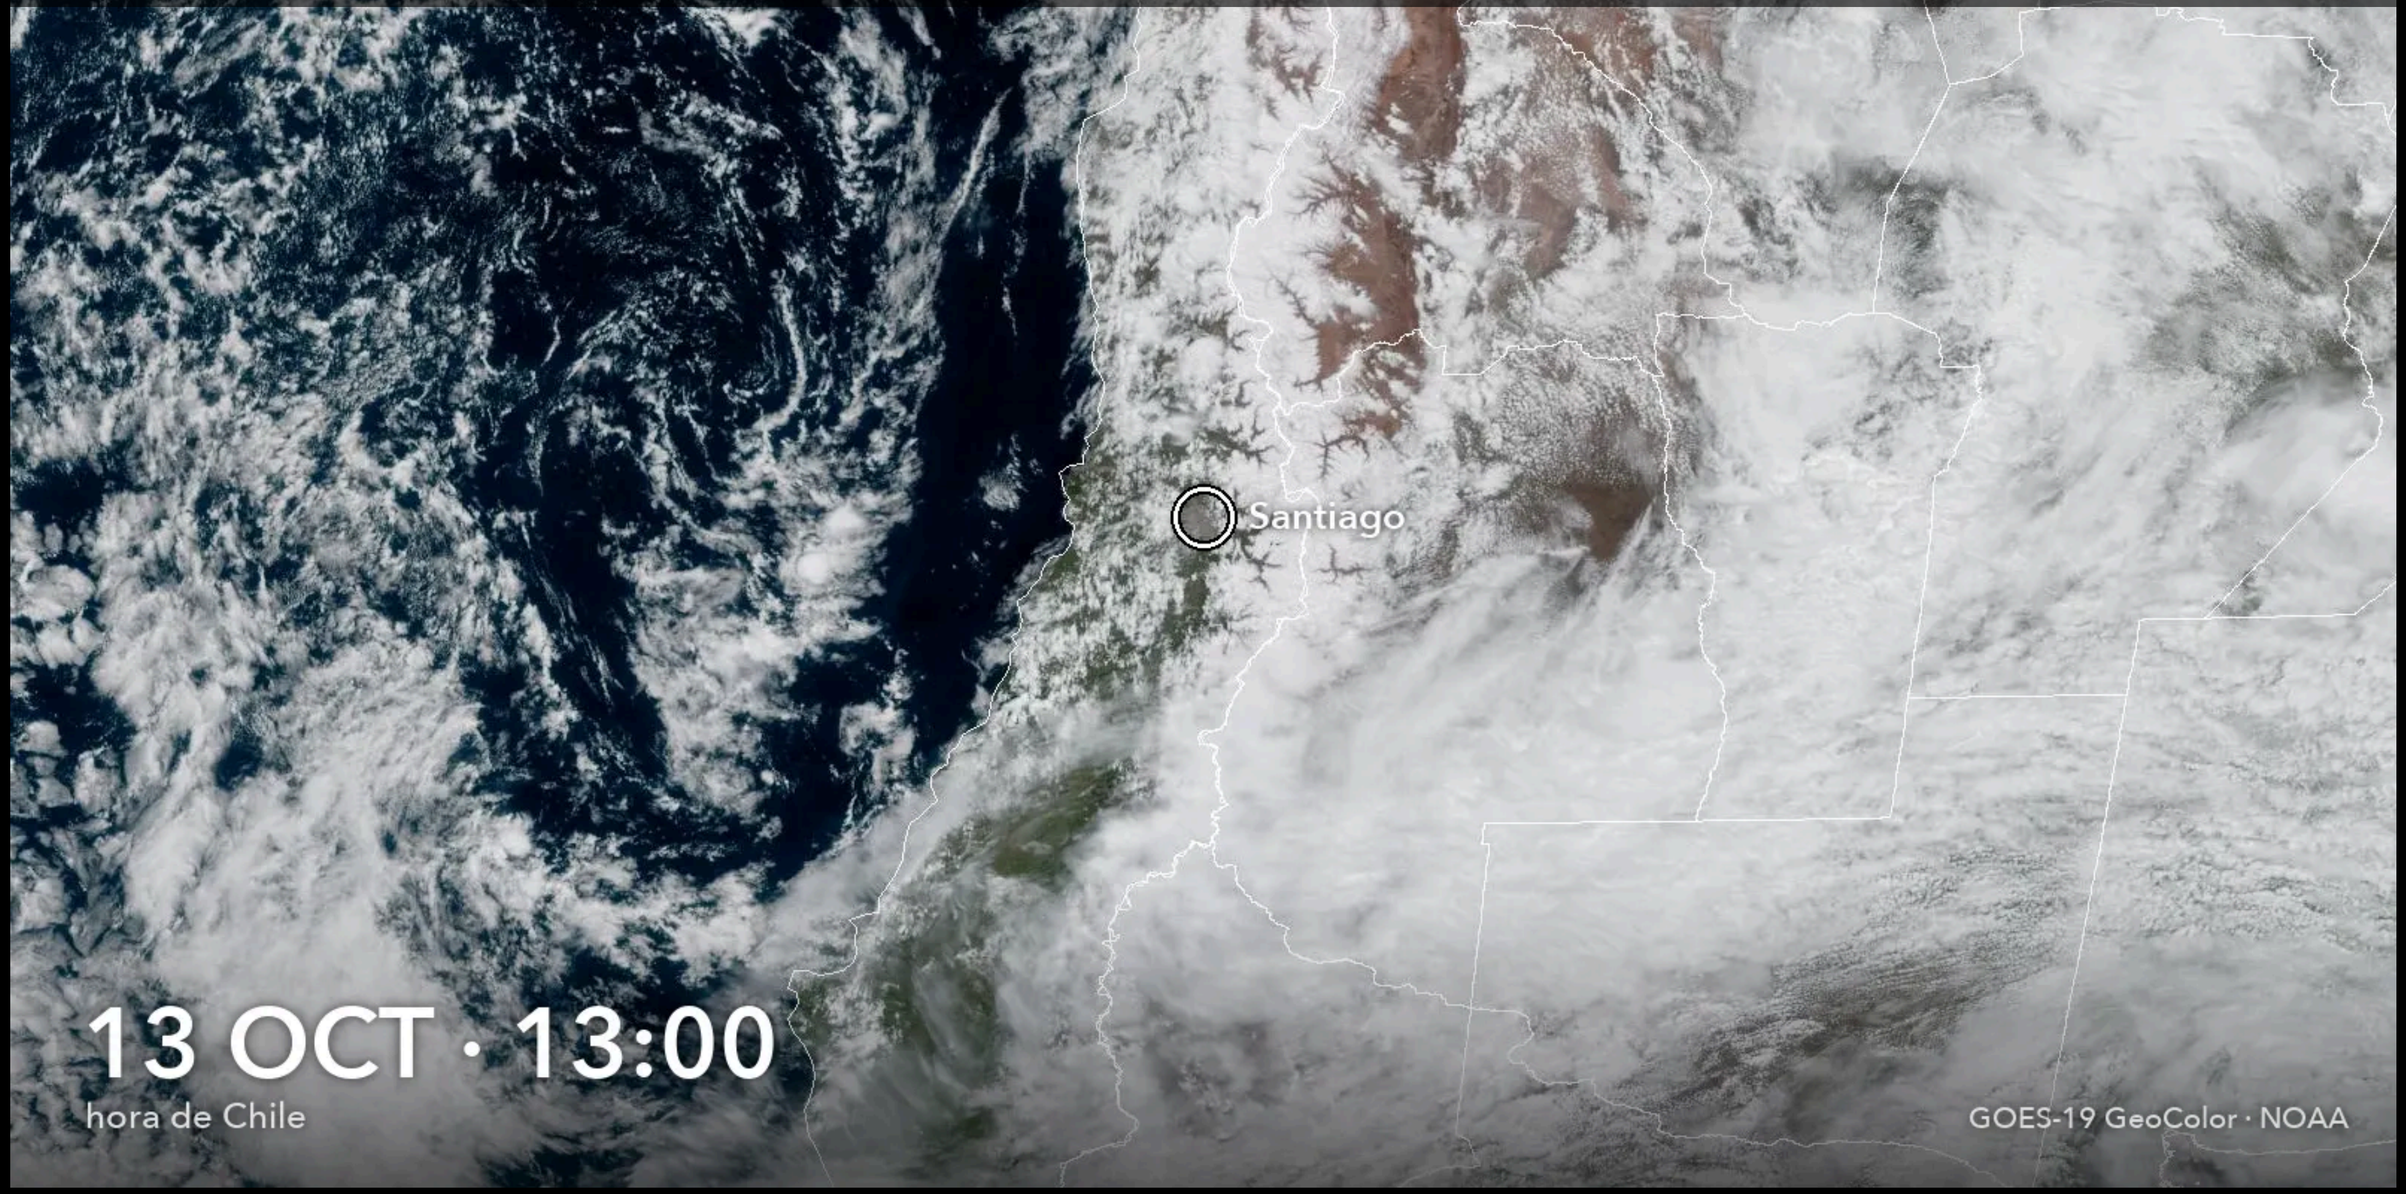
TESTIGO 02 DE 04

El satélite

¿La vio antes?

Gemini lee imágenes GOES-19 y las devuelve como columnas de una tabla.

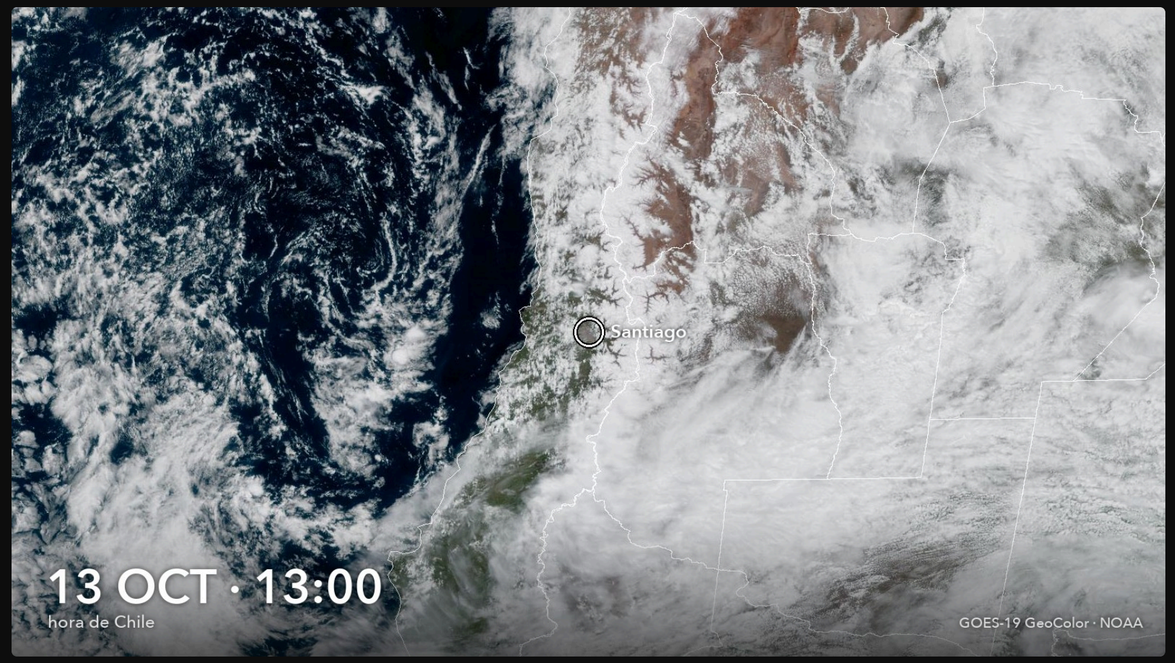
Así se veía Santiago desde el espacio · martes 13 de octubre



A 36.000 km de altura, una foto cada 10 minutos

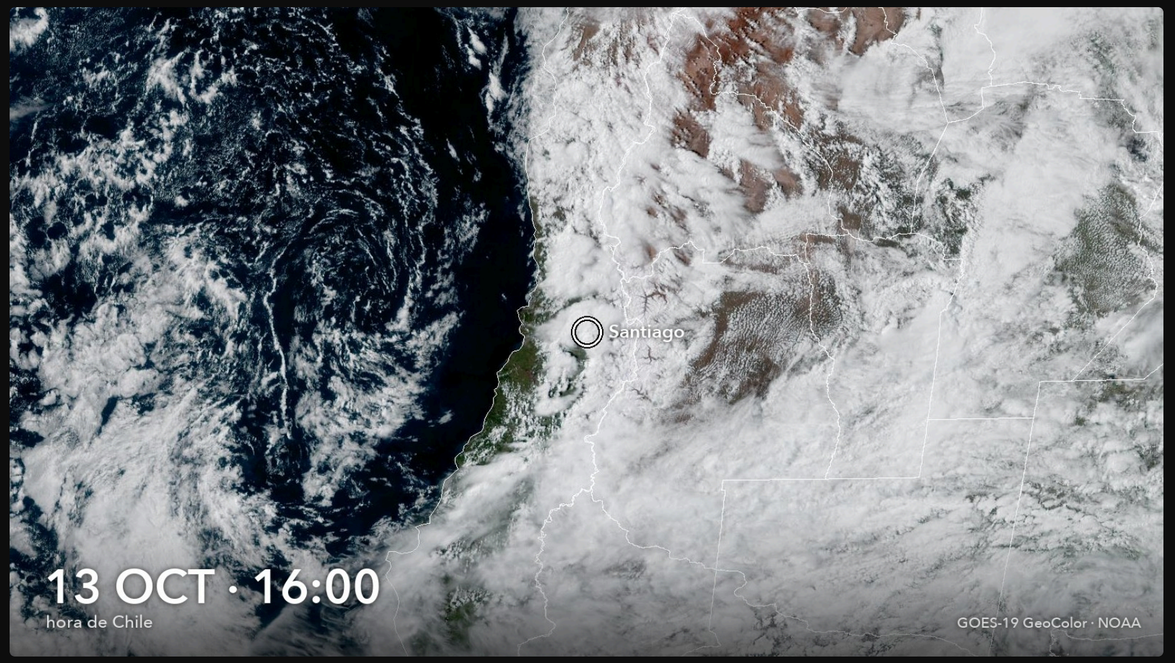


¿Y si esto fuera una tabla?



Antes · martes 13, 13:00

hora	intensidad	nubosidad	célula_sobre_santiago
13:00	1	2%	false



Durante · martes 13, 16:00

hora	intensidad	nubosidad	célula_sobre_santiago
16:00	8	95%	true

La misma imagen que impresiona es también **una fila que Gemini puede leer**.

AXMOS
UNLOCK THE EXTRAORDINARY

DEMO EN VIVO

La tormenta y los datos, en la misma pantalla

Una app con tres cosas sincronizadas, cuadro a cuadro:

- La imagen del satélite
- Lo que vio Gemini en esa hora
- La curva de clientes sin luz (SEC)

devfest-gdg-jarcen.cloud.run

13 OCT · 16:00

hora de Chile

Santiago

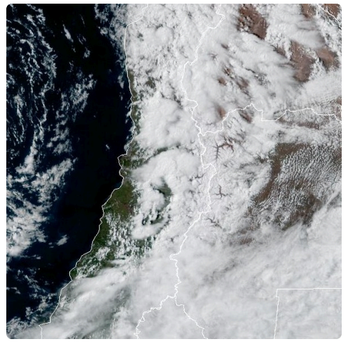
GOES-19 GeoColor · NOAA

ObjectRef: cuando una celda es una imagen

Lakehouse: BigQuery ya no es solo filas y columnas. Una tabla también puede apuntar a imágenes, PDF o audio que viven en Cloud Storage.

TABLA EN BIGQUERY

ts_chile	intensidad	imagen (ObjectRef)
15:00	4	`{uri: …/20261013T1800.jpg}`
16:00	8	`{uri: …/20261013T1900.jpg}`
17:00	7	`{uri: …/20261013T2000.jpg}`



Cloud Storage

`tu-bucket/horario/ir13/`

```
20261013T1800.jpg
20261013T1900.jpg
20261013T2000.jpg
… 1.034 archivos
```

QUÉ ES

Un **STRUCT** que apunta al archivo: `uri`, `version`, `authorizer`, `details`.

CÓMO SE CREA

OBJ.MAKE_REF(uri) desde una URI, o **OBJ.LIST('gs://.../*')**: una fila por archivo.

QUIÉN LO LEE

Las AI functions: **AI.GENERATE((prompt, ref))** recibe la imagen junto al texto.

> ***La fila guarda el puntero;*** *el archivo sigue en el bucket.*

Cómo "ve" Gemini una imagen

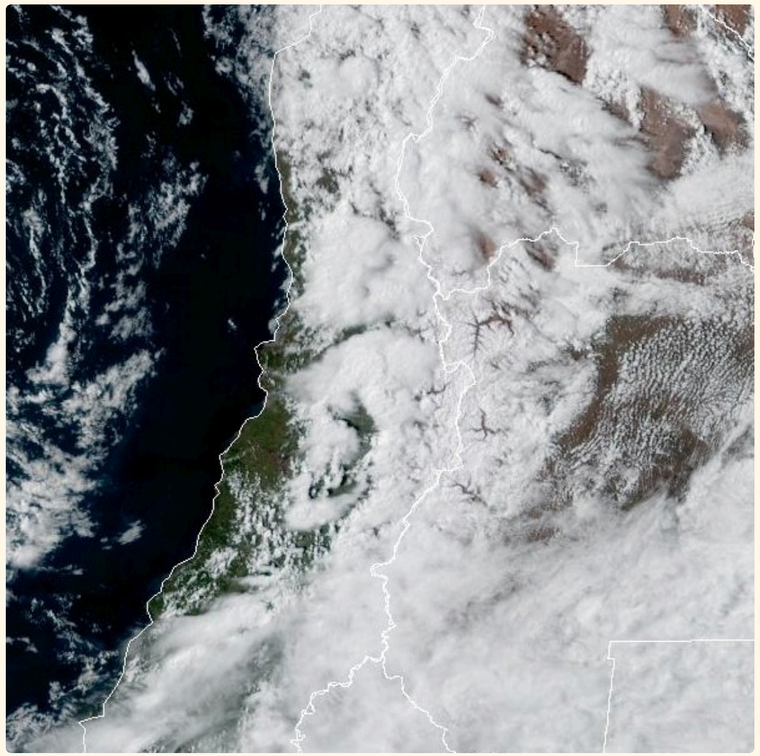
1. **Texto e imagen van en el mismo prompt:** `(prompt, OBJ.MAKE_REF(uri))`.

2. **La imagen se vuelve tokens, como el texto:** ~1.089 tokens por imagen de 512 px (unos 1.800 con el prompt).

3. **El modelo no sabe física: ve colores.** En infrarrojo, el color es la temperatura del tope de la nube.

4. **Díselo en el prompt y mejora:** describir la paleta bajó el ruido a la mitad.

5. **output_schema lo obliga a responder:** en una foto de calle sin cielo contestó "nubosidad 85%".



Lo que recibe Gemini: píxeles, sin costa, sin escala, sin leyenda.

> ***Gemini no mira el cielo: mira píxeles.*** *El prompt le dice qué significan.*

Imágenes como columnas

Sin connection

```
DECLARE prompt STRING DEFAULT '''
  Eres meteorólogo satelital. Santiago está al centro.
  Paleta IR: gris = despejado, verde = nube alta,
  naranja o rojo = convección. Intensidad de 0 a 10.''';

CREATE OR REPLACE TABLE trabajo.satelite_13oct AS
SELECT s.ts_chile, ai.*
FROM fuentes.satelite_horario AS s,
UNNEST([STRUCT(AI.GENERATE(
  (prompt, OBJ.MAKE_REF(s.uri)),
  output_schema ⇒ '''intensidad INT64, nubosidad_pct INT64,
    conveccion BOOL, celula_sobre_santiago BOOL'''
) AS ai)])
WHERE s.ts_chile BETWEEN DATETIME '2026-10-13 12:00:00'
                     AND DATETIME '2026-10-13 19:00:00';
```

1 · EL PROMPT, ARRIBA

Una variable: la query queda corta y el prompt se edita en un solo lugar.

2 · LA IMAGEN, POR FILA

OBJ.MAKE_REF convierte la uri de cada hora en un ObjectRef.

3 · LA RESPUESTA, TIPADA

output_schema define las columnas que devuelve.

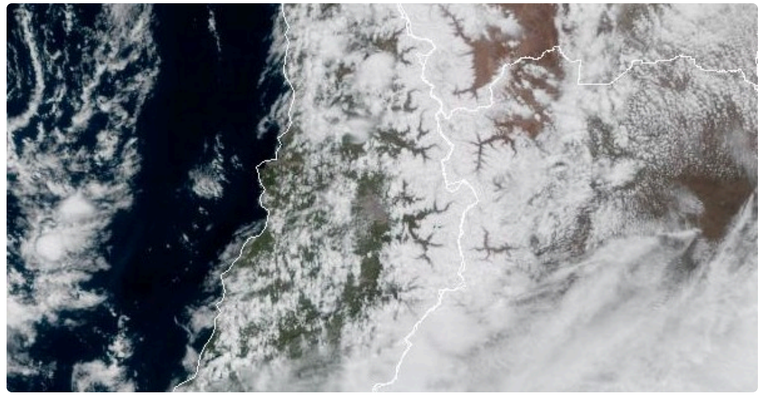
TU RESULTADO · 8 FILAS, ~20 S

12h 1 · 13h 1 · 14h 4 · 15h 5
16h 8 · 17h 7 · 18h 5 · 19h 6

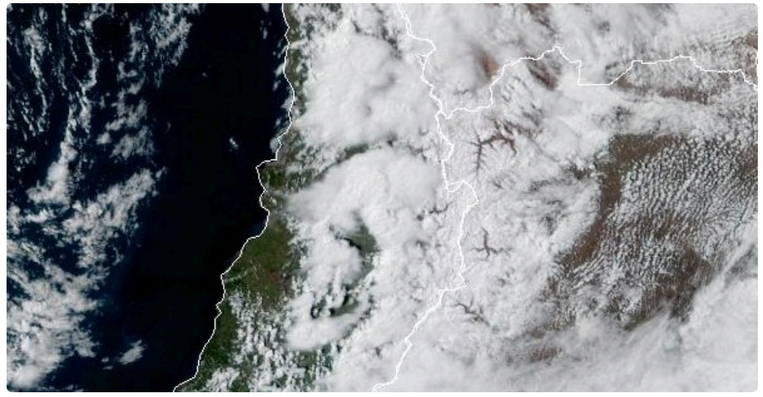
Versión corta del prompt. El prompt completo (describe la paleta del infrarrojo) está en la guía, paso C3.

13 de octubre, hora a hora

Lo que extrajo Gemini del satélite, junto a los clientes sin luz de la SEC



13:00 · intensidad 1



16:00 · intensidad 8, célula sobre Santiago

Hora	Intensidad	Nubosidad	Convección	Sin luz (SEC)
12:00	0	0%	no	3.730
13:00	1	2%	no	2.673
14:00	2	15%	no	2.894
15:00	4	25%	no	2.178
16:00	8	95%	sí, sobre Santiago	27.981
17:00	7	100%	sí	40.366
18:00	6	100%	no	34.681
19:00	2	10%	no	25.514

El satélite marcó 4 a las 15:00. *Los cortes saltaron a las 16:00.*

Cambiar de modelo es un argumento

POR DEFECTO · PARA EXPLORAR EN VIVO

gemini-3.5-flash-lite

Calidad (correlación)	**0,88**
Tiempo, 72 imágenes	**86 s**
Ruido entre horas vecinas	**0,77**
Costo	**menor**

```
-- sin endpoint
AI.GENERATE((prompt, ref),
  output_schema ⇒ ...)
```

MÁS PRECISO · PARA PRECALCULAR

gemini-3.8-flash

Calidad (correlación)	**0,90**
Tiempo, 72 imágenes	**377 s** (4,4×)
Ruido entre horas vecinas	**0,51**
Costo	**mayor**

```
-- un argumento más
AI.GENERATE((prompt, ref),
  endpoint ⇒ 'gemini-3.8-flash',
  output_schema ⇒ ...)
```

¿Qué modelo respondió? La información del job no lo dice; la respuesta sí: `JSON_VALUE(full_response, '$.model_version')`

AXMOS
UNLOCK THE EXTRAORDINARY

03

TESTIGO 03 DE 04

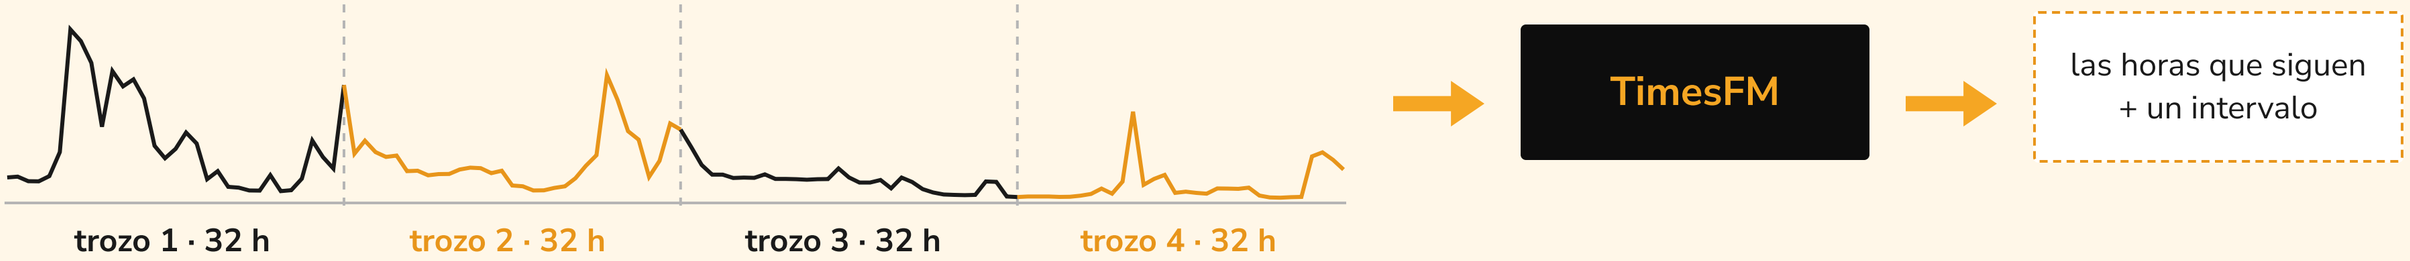
La serie

Un modelo que nunca vio Santiago

TimesFM 3.0 dentro de AI.FORECAST y AI.DETECT_ANOMALIES, sin entrenar nada.

¿Qué es un modelo fundacional de series?

Tu serie: clientes sin luz, las 128 horas antes del 13-oct a las 12:00



TimesFM corta tu serie en **trozos de 32 valores consecutivos** (32 horas en nuestra serie) y lee cada trozo **como un LLM lee una palabra**.

Se preentrena una vez con muchísimas series de dominios distintos: tráfico web, búsquedas, sintéticas.

Predice todo el horizonte de una pasada y entrega la mediana más un intervalo.

Normaliza cada serie: no sabe si son clientes, viajes o milímetros. Solo ve la forma.

Zero-shot: no aprende de tu serie, la usa como contexto. Si la curva nunca mostró algo, no tiene de dónde sacarlo.

> ***Un LLM completa frases.*** *TimesFM completa curvas.*

TimesFM: de un billón de puntos a tu serie

3.0 · Preview 7-oct

1.0

2024 · 200M parámetros

paper en ICML 2024

2.0

2025 · 500M parámetros

400 mil millones de puntos

2.5

sep 2025 · 200M

contexto de 16k · default en BQ

3.0

ago 2026 · 330M parámetros

más de un billón de puntos · multivariado con covariables

Benchmarks: #1 en fev-bench y TIME, y entre modelos fundacionales en GIFT-Eval, según Google.

Límites de 3.0 en BQ: contexto de hasta 2.048 puntos y horizonte de hasta 1.024.

Costo: hasta el 30-nov solo cómputo; desde el 1-dic, también tokens.

En BigQuery: AI.FORECAST, AI.DETECT_ANOMALIES, AI.EVALUATE, Connected Sheets y data agents.

Licencia: pesos no comerciales si los descargas; dentro de BigQuery, uso comercial permitido.

Se elige con model => 'TimesFM 3.0'; si no, usa 2.5.

> ***330 millones de parámetros*** *que se ejecutan dentro de tu SELECT.*

ARIMA aprende tu serie. TimesFM ya sabe de series.

	ARIMA_PLUS	TimesFM
Entrenamiento	CREATE MODEL, uno por serie	ninguno
Uso	modelo + ML.FORECAST	una función: AI.FORECAST
Personalización	alta: feriados, estacionalidad	baja
Explicabilidad	alta: ML.EXPLAIN_FORECAST	baja
Covariables	ARIMA_PLUS_XREG	3.0, en Preview

> ***Entrenar o preguntar:*** *elige según cuánto conoces tu serie.*

La apuesta: TimesFM sin ojos

TimesFM 3.0 · Preview

```
CREATE OR REPLACE TABLE trabajo.pronostico_ciego AS
SELECT * FROM AI.FORECAST(
  (SELECT ts_utc, clientes_afectados
   FROM fuentes.sec_rm_horario
   WHERE ts_utc < TIMESTAMP '2026-10-13 15:00:00+00'),
   -- = 13-oct a las 12:00 hora de Chile
  data_col ⇒ 'clientes_afectados',
  timestamp_col ⇒ 'ts_utc',
  horizon ⇒ 12,
  model ⇒ 'TimesFM 3.0');
```

Con la historia hasta el 13-oct a las 12:00, **¿cuánto pronostica para las 17:00?**

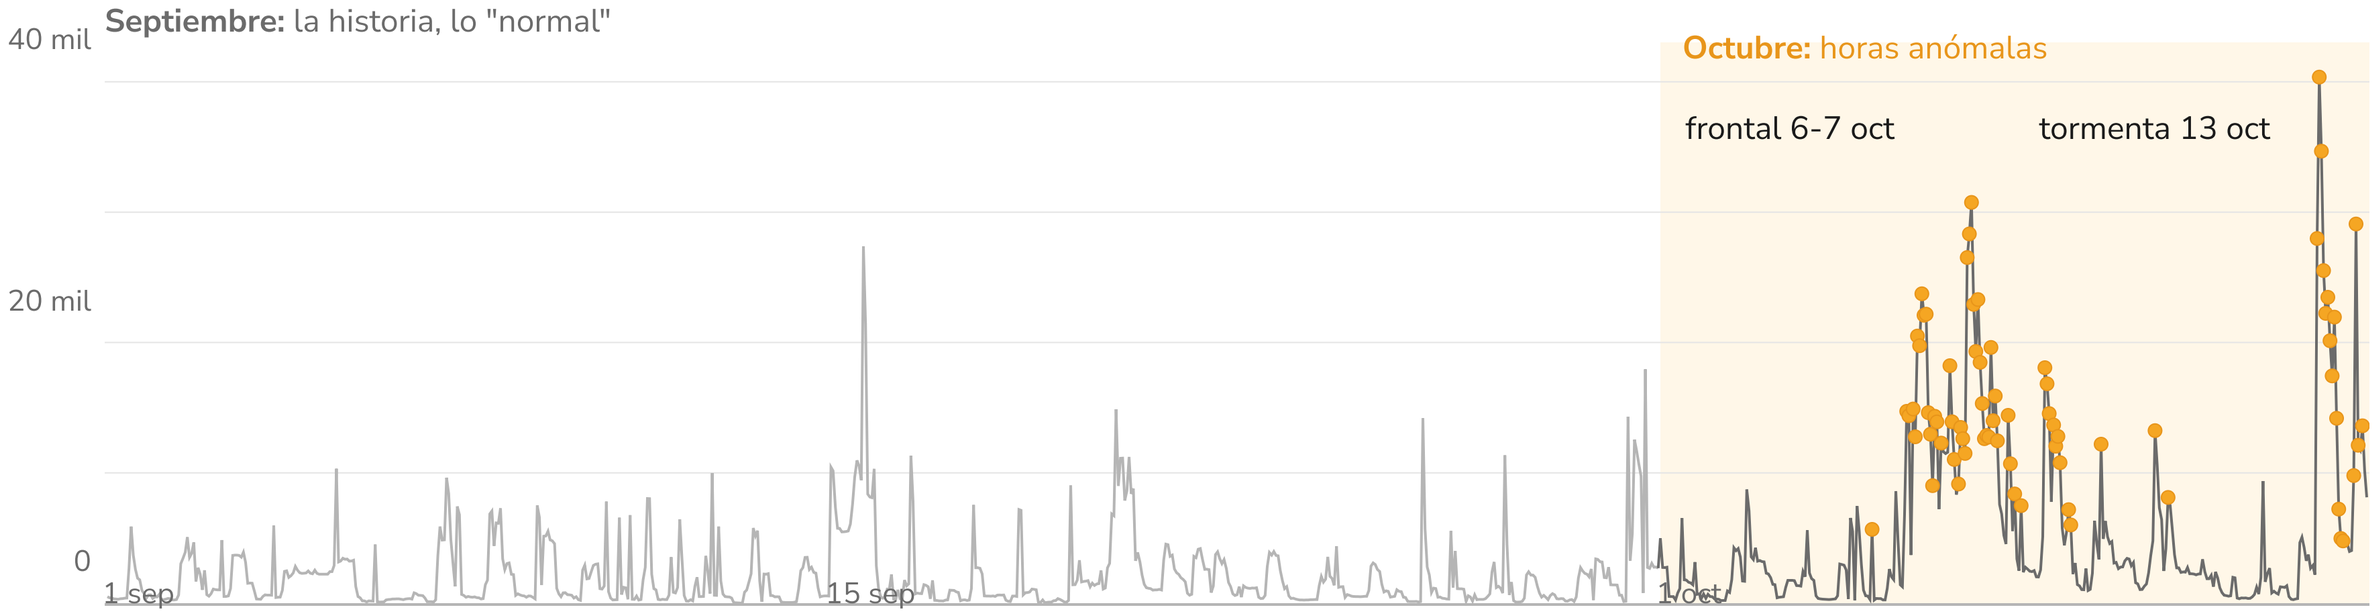
A) ~3 mil · B) ~15 mil · C) ~40 mil

Pronóstico (TimesFM 3.0)	**2.285**
Límite superior (95 %)	**13.687**
Real (SEC)	**40.366**

18× más de lo pronosticado. No es un mal modelo: **la serie nunca había visto algo así.**

Lo que sí sabe hacer: decir qué no es normal

Clientes sin luz en la RM, hora a hora, 1-sep → 14-oct · AI.DETECT_ANOMALIES con TimesFM 3.0




```
AI.DETECT_ANOMALIES(
  (SELECT ... WHERE ts_utc < 1-oct),  -- historia
  (SELECT ... WHERE ts_utc ⩾ 1-oct), -- a revisar
  data_col ⇒ 'clientes_afectados',
  model ⇒ 'TimesFM 3.0')
```

Septiembre le enseña qué es normal; *octubre se sale justo en los temporales.*

71 de 328 horas de octubre marcadas. Sin entrenar, sin CREATE MODEL.

Cómo leer un pronóstico

TimesFM 3.0 desde el 13-oct a las 15:00, sin y con los "ojos" de Gemini (covariables del satélite)

Hora	real	ciego	ciego_sup	con_ojos	con_ojos_sup
16:00	**27.981**	1.876	5.608	1.814	4.640
17:00	**40.366**	1.750	7.677	1.604	5.375
18:00	**34.681**	1.685	8.393	1.525	6.001
19:00	**25.514**	1.531	8.674	1.378	6.461
20:00	**22.235**	1.381	8.640	1.244	6.909
21:00	**23.470**	1.054	8.416	1.058	7.166

1. **ciego / con_ojos = la mediana:** el valor más probable, lo que el modelo apuesta.
2. ***_sup = el techo del intervalo al 95 %:** según el modelo, superarlo es muy improbable.
3. **El real cae fuera de la banda** en las 6 horas: a las 17:00, 40.366 contra un techo de 7.677.
4. **Con ojos no ensanchó la banda:** 5.375 contra 7.677. Las covariables del satélite no ayudaron.

Una covariable sirve si explica la serie, *no porque sea impresionante.*

AXMOS
UNLOCK THE EXTRAORDINARY

04

TESTIGO 04 DE 04

Un agente

¿Sabe lo que no sabe?

Un data agent de Conversational Analytics sobre la SEC, la lluvia de la DMC y el satélite.

Qué es un data agent

GA · jun 2026

PREGUNTA
en español

→

LLM + CAPA SEMÁNTICA
entiende qué le preguntas

→

HERRAMIENTAS
SQL, AI.FORECAST, anomalías

→

RESPUESTA
con el SQL visible

Lo que lo separa de un chatbot es la **capa semántica**: lo que le explicarías a un analista nuevo el primer día.

Instrucciones

Reglas: "habla en hora de Chile".

Glosario

Qué significa "corte masivo".

Verified queries

Respuestas ya aprobadas.

> ***El modelo pone el lenguaje;*** *tú pones el significado.*

Conversational Analytics en BigQuery · agentes en free trial hasta el 31-dic-2026

Un agente que conoce la emergencia

GA · jun 2026

FUENTES

sec_rm_horario · sec_rm_comuna_horario · lluvia_dmc_diaria · satelite_horario · estaciones_dmc

INSTRUCCIONES

Habla en hora de Chile. Quinta Normal es la estación de referencia. Filtra dato_sospechoso.

GLOSARIO

"Corte masivo", "día de lluvia", "estación de referencia"

VERIFIED QUERIES

Peak diario de cortes · lluvia por estación · horas anómalas

¿Qué día de octubre hubo más clientes sin luz en la RM, a qué hora, y cuánto llovió ese día en Quinta Normal?

El **13 de octubre a las 17:00**, con **40.366 clientes** afectados en 49 comunas. Ese día Quinta Normal registró **13,4 mm**.

Generó un JOIN entre la SEC y la DMC, aplicó el filtro de las instrucciones y sugirió tres preguntas de seguimiento.

La pregunta trampa

"¿Fue el octubre más lluvioso de la historia en Santiago?"

La tabla de lluvia empieza en 2016. El récord de 1930 no está en los datos.

SIN LA REGLA

"**Sí**, dentro del registro histórico disponible (2016-2026)... es por amplio margen el octubre más lluvioso."

Y lo titula: **"Récord Histórico de Precipitaciones"**.

CON LA REGLA

"108 mm... el octubre más lluvioso **dentro del registro disponible (2016–2026)**, superando al segundo lugar (2017, 35,5 mm)."

Y lo titula: **"Récord en la serie 2016–2026"**.

Una línea de instrucción *separa "récord histórico" de "récord en los datos que tengo".*

Dos aluviones, 33 años de distancia

QUEBRADA DE MACUL · 3 MAYO 1993

26 fallecidos

32.654 damnificados

QUEBRADA HONDA · 8 OCTUBRE 2026

0 fallecidos

384 damnificados

Y aun así, no había un pluviómetro dentro de la cuenca afectada.

Ningún modelo ve lo que no se mide. Los datos de la próxima emergencia se instalan antes de que llueva.

Fuentes: ONEMI (1993) · Senapred, balance del 10-oct-2026 · CR2, Universidad de Chile

¿Quién vio venir la tormenta?

LA PRENSA	**Después,** y con cinco cifras distintas. AI.AGG explicó por qué.
EL SATÉLITE	**Una hora antes:** intensidad 4 a las 15:00; los cortes saltaron a las 16:00.
LA SERIE	**No la vio,** pero supo que fue anómala. Zero-shot no es clarividencia.
EL AGENTE	**Responde bien** cuando le enseñas el significado, y dice qué no sabe.

Ninguno basta solo: *el valor está en cruzarlos, y en saber cuándo no creerles.*



Gracias. ¿Preguntas?

javier@axmos.tech · linkedin.com/in/jarcen

DEVFEST CLOUD SANTIAGO 2026 · INACAP APOQUINDO